



Journal of Knowledge Information Technology and Systems

ISSN 1975-7700 (Print), ISSN 2734-0570 (Online)

<http://www.kkits.or.kr>



A Design of Anomaly Behavior Detection System Based on Deep Learning Model Using CCTV

Yong Ju Lee*

Department of Mechatronic engineering, Korea Polytechnic University Cheongju Campus

ABSTRACT

CCTV is undoubtedly the field that produces the most video data and uses the video analysis technology the most. In the mean time, CCTVs have been operated mainly for the purpose of crime prevention or control. In particular, as smart city projects have been promoted in recent years, the number of CCTVs operated by public institutions is increasing. As the number of CCTVs for crime prevention and control increases, the problem of a shortage of control personnel is occurring. In this way, a lot of human resources are required to continuously analyze the video stream collected from CCTV for crime prevention and control purposes, and automation research to solve the labor-intensive camera monitoring problem has become inevitable. To overcome this problem, this paper implements a system that detects abnormal behavior in CCTV images using deep learning. As a method for detecting abnormal behavior, a 2-class classification method that divides abnormal behavior and normal behavior using the UCF-Crime dataset is applied and tested. Behavior patterns are inferred by inputting data that has undergone preprocessing of video data to the trained model. Through the experiment, it is possible to obtain the effect of responding to abnormal behavior patterns by classifying the abnormal behavior patterns based on the deep learning system-based reliable judgment rather than the artificial judgment of the controllers. In the future, it is possible to study specific behavior pattern analysis through diversification of detailed behavior patterns and reliability improvement algorithms of the inference model.

© 2022 KKITS All rights reserved

KEYWORDS: Deep learning, UCF-Crime dataset, Behavior pattern, Abnormal behavior, Inference model

ARTICLE INFO: Received 13 January 2022, Revised 28 February 2022, Accepted 8 April 2022.

*Corresponding author is with the Department of Electronic Engineering from Chung Ang University in 1989 and Ph.D. degree in the Department of Electronic

Engineering from Chung Nam University in 2001.
E-mail address: yoongju@kopo.ac.kr

1. 서 론

1.1 배경

오늘날 영상 데이터를 가장 많이 생산하고, 영상 분석 기술을 가장 적극적으로 활용하고 있는 분야는 단연 CCTV일 것이다. 그동안 지자체에서는 주로 방법이나 관제 목적으로 많은 수의 CCTV를 운영해왔으며, 이들에게서 얻어지는 전국 공공기관의 영상 데이터만 고려해도 그 양은 감히 상상할 수 없을 정도다. 특히 최근 몇 년 간 스마트시티 프로젝트 등이 추진되면서 공공기관이 운영하는 CCTV 대수는 더욱 늘어나고 있다.

이처럼 방법 및 관제 목적의 CCTV가 늘어나면서 관제 인력이 부족해지는 문제가 발생하고 있다. 수백~수천 대의 CCTV를 운영하는 지자체들은 별도의 영상 관제센터를 설치하고 이상 현상이 발생하는지를 실시간으로 감시하고 있다. 사건이 발생한 즉시 혹은 발생하기 전에 인식하고 대응하려면 문제 행위가 촬영되는 즉시 행동에 나서야 하기 때문이다. 하지만 CCTV 설치 대수가 기하급수적으로 늘어나면서 모든 영상을 사람이 실시간으로 감시하는 것은 불가능에 가까워졌다. 특히 우리나라는 CCTV가 많은 것으로 유명하다. <그림 1>은 2010년부터 2015년까지 전국 방법용 CCTV 설치 현황을 나타낸 것이다. CCTV 설치가 점점 증가하는 것을 알 수 있다. 현재는 CCTV가 없는 곳을 찾아보기 힘들 정도이다[1].

CCTV는 범죄 예방뿐만 아니라 정보 수집, 범인의 체포, 범죄에 대한 심리적 두려움의 증가 등의 기능을 수행하기도 한다. CCTV의 존재 사실을 인식하면 범행에 심리적 부담감을 주기 때문에 잠재적 범죄자에 대해 범죄 예방 효과가 있는 것으로 보인다. 하지만 미국과 영국의 CCTV 효과성 분석에 따르면 절도와 강도죄의 경우 어느 정도 효과

성이 입증되었지만, 충동적 범죄의 경우 억제력이 크지 않은 것으로 나타났다. 또한 CCTV 설치 구역에서의 위법행위가 발각되지 않을 경우 범죄자들의 심리적 부담감이 줄어들게 된다. 이와 같은 경우 CCTV를 통한 신속한 사건 발생 여부 파악과 초동대응은 충동적 범죄를 막을 수 있는 확률을 높이고 재범률을 낮추는 데 중요한 역할을 한다.

(단위 : 대)

연도	계	서울	부산	대구	인천	광주	대전	울산	경기	강원	충북	충남	전북	전남	경북	경남	제주
2010	36,107	8,197	460	1,117	2,066	401	521	532	9,471	2,006	1,164	2,143	1,078	1,552	2,377	1,854	168
2011	48,446	10,124	1,046	1,538	2,426	412	972	823	13,705	2,717	1,764	2,932	1,526	2,220	3,280	2,707	284
2012	64,596	11,938	1,673	2,177	3,059	491	1,369	1,122	18,550	3,370	2,899	3,974	2,285	3,183	4,271	3,602	633
2013	90,931	14,070	2,430	2,789	3,859	2,895	1,561	1,822	28,363	4,341	3,698	5,580	3,736	4,000	5,706	5,228	1,054
2014	123,710	21,413	3,443	3,894	4,991	3,115	3,482	2,180	36,963	5,005	4,587	7,122	4,681	4,627	7,948	7,213	3,046
2015.9	141,687	23,323	3,954	4,167	5,175	3,372	3,574	3,075	41,870	5,637	5,384	8,382	5,192	5,419	10,042	9,305	3,806

그림 1. 방법용 CCTV 설치 현황

Figure 1. CCTV installation status

CCTV를 통한 신속한 사건 발생 여부 파악과 초동 대응을 하기 위하여 우리나라는 관제센터를 운영하고 있다. 관제센터는 범죄와 사건·사고를 예방하고 유사시 초동대응을 할 수 있도록 관제사들이 CCTV 화면을 분할해서 24시간 감시하는 기능을 한다. 관제센터는 분명히 범죄 예방에 도움을 주고 있지만, 한계점은 명확하다. 너무나도 많은 화면을 소수의 사람이 오랜 시간 정확하게 감시하는 것은 불가능하기 때문이다. 이러한 문제점으로 현재 CCTV는 사건의 예방보다 사건 발생 후 증거 자료로 쓰이는 경우가 대부분이다.

1.2 필요성 및 목적

본 논문에서는 위와 같은 관제센터의 한계점을

극복하고 CCTV의 범죄 예방 효과를 강화하기 위해 딥 러닝 기반의 이상 행동 감지 시스템을 구현한다.

이상 행동을 감지하기 위해 본 논문에서는 UCF-Crime 데이터세트를 사용하여 이상 행동과 정상 행동으로 구분하는 2-class 분류 문제로 다루었다. UCF-Crime 데이터세트는 128시간 분량의 동영상으로 구성된 대규모 데이터세트입니다. 그것은 학대, 체포, 방화, 폭행, 도로 사고, 강도, 폭발, 싸움, 강도, 총격, 절도, 줌독극, 기물 파손을 포함한 13가지 사실적인 변칙이 포함된 1900개의 길고 다듬지 않은 실제 감시 비디오로 구성되어 있다. 그러나 연구에 의하면 UCF-Crime 데이터세트로는 기존의 행동 인식 방식을 사용할 수 없다[2]. 따라서 본 논문에서는 심층의 모델을 사용하여 이상 행동과 정상 행동을 분류하여 이상 행동을 감지하고 이전 실험과 비교를 위해 비디오 데이터세트를 이미지로 변환시킬 때 조건을 최대한 동일하게 진행하였다.

본 논문의 구성은 다음과 같다. 2장에서 딥러닝의 추론 모델에 대한 관련연구, 3장에서는 시스템 구조 및 설계, 4장에서는 모델 훈련과 성능 평가를 설명하고, 5장 결론으로 구성하였다.

2. 관련 연구

2.1 ResNet

일반적으로 인공지능망의 성능은 모델의 깊이가 깊을수록 좋은 성능이 나올 것이라 생각한다. 그러나 모델의 깊이가 깊어질수록 계산량이 많아지고 기울기가 소실 혹은 폭주하는 문제가 발생한다. 이러한 문제를 해결하기 위해 shortcut connection을 도입한 ResNet (Residual Network) 모델이 제안되었다[3].

〈그림 2〉는 ResNet의 residual block이다. 기존의 CNN은 shortcut connection이 없었기 때문에 모델의 결과값은 수많은 행렬의 곱셈으로 표현되었다. 〈그림 2〉 오른쪽의 shortcut connection을 통해 모델의 결과값을 출력값과 입력값의 덧셈으로 간단하게 표현할 수 있게 된다[3,6].




그림 2. 잉여 블록
Figure 2. Residual Block

layer 간의 연결에 중간을 뛰어넘어서 전달하는 Shortcut을 추가하면 학습 과정에서 이전 값이 다음 값으로 전달될 때 feature가 크게 변하는 기존 CNN과 달리 이전 값에서 얼마만큼만 변하는지 계산하는 문제가 된다. 따라서 연산이 간단하고 빠른 학습이 가능해진다. 이러한 구조를 shortcut connection이라고 하고 입력값 x 가 그대로 전달되는 과정을 identity mapping이라고 한다. 결과적으로 ResNet은 residual block을 도입하여 모델의 층을 늘리고 성능을 개선했다.

2.2 C3D

CNN(Convolutional Neural Network)은 2D Convolution kernel을 사용하여 이미지를 인식하기 위한 패턴을 찾는 데에 유용하게 사용되고 있다. 2D Convolution kernel 사용 이전에는 이미지 데이터에 대한 모델 훈련에 어려움이 있었다. 그 이유

는 모델의 입력 데이터의 차원이 1차원으로 한정되어 있었기 때문이다. 그래서 이미지 데이터를 학습시키기 위해서는 3차원인 이미지 데이터를 1차원으로 평면화시켜야 했다. 이 과정에서 공간 정보가 손실되어 학습이 비효율적이었으며 높은 정확도를 얻는 데에 한계가 있었다. CNN을 사용하면서 이러한 한계를 극복하고 이미지의 공간 정보를 유지한 채 학습할 수 있게 되었다[2,8,9].

C3D(Convolutional 3D)는 앞에서 설명한 CNN의 2D Convolution kernel의 차원을 늘린 3D Convolution kernel을 사용한다. C3D 모델은 비디오 데이터에 대해 시간 정보를 고려하기 위해 고안된 모델로서 3D Convolution kernel은 많은 매개변수로 인해 과적합 되는 경향이 있지만, 최근에 대규모 비디오 데이터세트로 인해 크게 개선될 수 있었다[3,4].

2.3 3D ResNet

이상 행동과 정상 행동 사이의 경계는 명확하지 않고 일반적으로 모호하다. 이는 이상 행동과 정상 행동에 대한 정의가 매우 주관적이기 때문이다. 그렇기 때문에 같은 행동이 조건에 따라 이상 행동이거나 정상 행동일 수 있다.

3D CNN의 구조는 ResNet에 비해 깊이가 얕으므로 기존의 2D 기반의 ResNet을 3D로 확장한 3D ResNet 모델이 개발되었으며 이로 인해 많은 매개변수를 가지고 있음에도 불구하고 과적합 현상이 발생하지 않았고, 상대적으로 C3D 모델에 비해 좋은 성능을 달성했다[4,5]. 본 논문에서는 3D ResNet을 이용하여 이상 행동 감지 시스템을 구현하려고 한다.

3. 시스템 구조 및 설계

3.1 데이터 세트

본 연구에서 사용하는 데이터 세트는 UCF-Crime 데이터 세트이다. UCF-Crime 데이터 세트는 총 13개의 이상 행동을 포함한 비디오와 정상 행동 비디오로 구성되어 있다. 데이터세트는 총 1,900개이며 이상 행동과 정상 행동은 각각 950개이다. 이미지 데이터를 사용할 때보다 확연히 적은 개수이나, 비디오 데이터세트에서는 큰 규모에 해당한다. 그리고 다른 데이터세트보다 현실적인 상황을 잘 반영하고 있기 때문에 이 데이터세트를 사용하였다[5,6,9].

훈련 데이터세트의 레이블은 하나의 비디오에 하나의 레이블이 존재한다. 본 논문에서는 비디오 레벨에서의 레이블을 이용하여 이상 비디오와 정상 비디오로 분류한다.

3.2 데이터 전처리

훈련을 위한 데이터세트는 데이터세트와 함께 제공되는 파일의 내용을 바탕으로 학습 데이터 1,610개와 테스트 데이터 290개로 나누었다[7,14,15]. 다음으로 각 비디오의 프레임을 이미지로 변환하여 저장한다. 이미지로 변환할 때 프레임의 크기를 240 x 320 픽셀로 조정하고 프레임 속도는 30fps이다.

3.3 시스템 구성과 모델 분석

전체적인 시스템 구성은 <그림 3>과 같다. 비디오 형식의 데이터세트를 이미지로 변환한 후 3D ResNet 모델의 입력으로 사용한다. <그림 4>와 <그림 5>는 학습과정을 통한 3D ResNet 18모델의 구조를 분석한 것이며, 이 모델은 학습과정을 통하여 이상 행동과 정상행동에 대한 추론 값을 가지고

있어서 <그림 4>의 입력으로 CCTV의 여러 이미지 묶음이 입력되면 추론모델은 입력 데이터 셋에 대해 이상 행동 혹은 정상 행동으로 분류된 결과값을 <그림 5>의 출력으로 제공한다. 본 논문에서 사용된 3D ResNet의 구조는 <그림 4>과 <그림 5>에 서와 같이 유사한 블록들의 층(layer)으로 18개의 반복 구조를 통해 반복적으로 학습함을 알 수 있다.

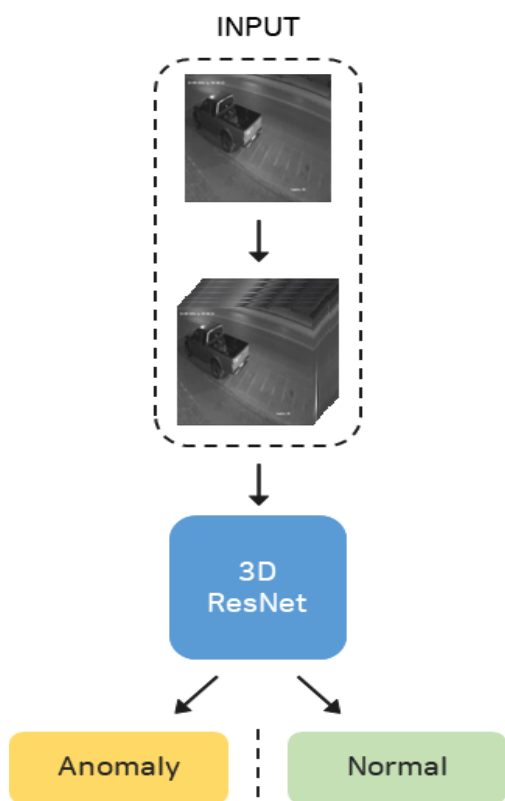


그림 3. 전체 시스템 구성
Figure 3. system configuration



그림 4. 3D ResNet 모델구조1
Figure 4. 3D ResNet structure1

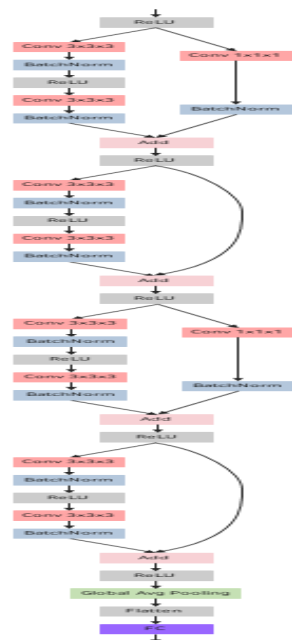


그림 5. 3D 모델구조2
Figure 5. 3D ResNet structure2

4. 모델 훈련 및 성능 평가

4.1 모델 훈련

이상 행동 비디오와 정상 행동 비디오가 모델의 입력으로 사용된다. 비디오 데이터는 전처리 과정을 거쳐 이미지 데이터로 저장되어 있다. 각각의 비디오에서 추출한 이미지는 순서를 가진 시퀀스로 입력된다. 이때 이미지를 모두 사용하지 않고 고정된 길이의 연속된 프레임만 사용한다. 입력의 레이블은 원-핫 인코딩(One-Hot Encoding)을 사용하였다. 반복 학습된 모델은 입력 시퀀스에 따라 입력된 비디오데이터가 이상 행동인지 정상 행동인지 추론 값에 따라 분류한다.

4.2 성능 평가

모델의 정확도를 높이기 위하여 <그림 4>와 <그림 5>의 구조에서 보듯이 18개의 반복 구조를 통해 깊이를 높였으며 다양한 클래스로 구분하는 것보다는 정상과 비정상 클래스 구분을 통하여 분석결과의 정확도를 높이도록 하였다.

<표 1>은 UCF-Crime 데이터세트에 대해 Binary SVM classifier를 이용하여 실험한 결과와 본 논문에서의 사용한 모델 간의 정확도를 비교한 결과이다[2].

표 1. Binary classifier와 3D ResNet의 이상 행동 감지 결과
Table 1. Accuracy of Binary classifier and 3D ResNet

Method	Binary classifier	3D ResNet
Accuracy	50.0	82.76

UCF-Crime 데이터세트의 변칙은 대부분 짧은 시간 동안 발생하며 비디오의 길이가 길기 때문에

기존의 행동 인식 방식을 사용할 수 없다[2,8,9]. 기존의 행동 인식 방법은 비디오의 전체 구간을 훈련하는 것이 아니라, 특정 구간만으로 훈련한다. 그렇기 때문에 비디오 수준의 레이블이 이상 행동인데, 이상 행동이 포함되지 않는 구간이 모델의 입력으로 사용될 수 있다. 그러나 본 논문에서는 3D ResNet 모델을 사용하여 두 개의 클래스로 분류할 때 약 82.76%의 정확도를 얻었다. 물론 다양한 비정상행동 클래스로 구분할 수도 있으나 이 경우 알고리즘의 고도화 및 분석 결과의 정확도가 낮아질 수 있다. 이전 모델의 실험 결과와 비교하기 위해 데이터 전처리를 비슷한 조건으로 진행하였으며[12,14], 그 결과 정확도가 Binary classifier 방법보다 32.76% 개선되었다. 이 결과는 모델의 깊이를 늘리고 공간 정보와 시간 정보를 모두 활용하여 훈련한 모델이 보다 정확도가 높은 추론 값을 얻을 수 있는 것으로 분석된다.

4.3 추론

훈련된 모델을 시험하기 위해 훈련된 모델에 대해 두 가지 실험을 진행하였다. 첫 번째는 비디오의 특정 구간을 모델의 입력으로 넣었을 경우에 이상 행동과 정상 행동 비율에 대한 점수를 비교한다. 두 번째는 비디오 전체 구간을 모델의 입력으로 사용하여 모델의 결과 값의 변화를 확인하려고 한다.

<그림 6>은 기물과손에 해당하는 이상 행동 데이터의 일부분이다. 이상 행동이 발생하는 구간의 이미지인 <그림 6>을 모델의 입력으로 사용하였다.

모델의 출력 값에 Softmax 함수를 적용하면 <표 2>와 같은 결과를 확인할 수 있다. <표 2>를 통해 이상 행동 클래스는 정상 행동 클래스와 비교하면 높은 값을 가지는 것을 확인할 수 있다. 이때 비정상 확률이 r 이라면 정상 확률은 $1-r$ 이 된다. 물론

클래스를 다양하게하여 추론할 수 있으나 이 경우 추론 값의 정확도는 낮아지게 되고 이를 높이기 위한 신뢰성 있는 모델이 요구된다.




그림 6. 이상 행동 데이터
Figure 6. Abnormal behavior data

표 2. 이상 행동 데이터에 대한 모델 추론 값
Table 2. model inference result

Class	Result
Anomaly(r)	0.98821
Normal(1-r)	0.01179

다음으로 하나의 영상에서 이상 행동 감지를 확인하기 위해 훈련된 모델의 입력으로 비디오의 전체 구간을 사용하였다. 입력으로 사용된 비디오는 UCF-Crime 데이터세트의 테스트 데이터다[10,14].




그림 7. 비디오 영상 전체 구간의 결과
Figure7. Video Result of entire image section

비디오 전체 구간을 모델의 입력으로 사용했을 때 <그림 7>과 같은 결과를 확인할 수 있다. 이상 행동 비디오 데이터에는 정상 행동이 포함되어 있기 때문에 <그림 7>의 왼쪽과 같은 결과가 나올 수 있다. 이상 행동이 발생할 경우 <그림 7>의 오른쪽과 같은 결과를 확인할 수 있다.

정상 행동만을 포함하고 있는 비디오를 모델의 입력으로 사용하게 되면 <그림 8>과 같은 결과를 확인할 수 있다.



그림 8. 정상 행동만 포함된 결과
Figure 8.Video results of normal behavior

훈련된 모델을 평가하기 위해 테스트 데이터에 대해 <그림 9>와 같이 confusion matrix를 그렸다. <그림 9>를 통해 모델이 얼마나 정확하게 분류하였는지 확인할 수 있다[15].




그림 9. 컨퓨전 매트릭스
Figure 9. Confusion matrix

5. 결론 및 향후 연구과제

본 논문에서는 3D ResNet 모델과 UCF-Crime 데이터세트를 이용하여 이상 행동을 감지하는 시스템을 구현하였다. 18개의 반복구조를 통해 깊이를 더하여 분석한 결과 값의 정확도를 관찰하였으며 다양한 클래스가 아닌 확장성을 고려한 2클래스 분류를 실험하였다. 실험을 통해 82.76%의 정확도를 달성하였고 UCF-Crime 데이터 세트로 두 개의 클래스로 분류 방법은 비교적 양호한 정확도로 분류할 수 있음을 보였다.

실험을 통해 사람에 의한 수동적 인위적 판단이 아닌 딥러닝 시스템 기반의 신뢰도 높은 판단으로 이상행동 패턴을 감지하여 이에 대처할 수 있는 효과를 얻을 수 있다. 향후 2-class분류방법을 고도화하여 추론 모델의 세부행동 패턴의 다양화 즉 이상 행동의 다양한 클래스 분류 및 신뢰도 향상 알고리즘을 통해 구체적인 행동패턴분석을 연구할 수 있으며 그 결과 적은 인력으로도 관계센터의 보다 효율적인 방법시스템 운영을 가능하게 하고 선제적 범죄 예방 효과의 강화를 기대한다.

References

- [1] CCTV Istallation Status for Crime Prevention, <http://www.cctvnews.co.kr/news/articleView.html?idxno=41933>, 2016.
- [2] S. T. Waqas, M. B. Shah, *Real-world anomaly detection in surveillance videos*. Proceedings of the IEEE conference on computer vision and pattern recognition, arXiv:1801.04264, pp. 6479-6488, 2018.
- [3] H. Kaiming, *Deep residual learning for image recognition*. Proceedings of the IEEE conference on computer vision and pattern recognition, arXiv:1512.03385, pp. 770-778, 2016.
- [4] K. S. Hara, H. k. Kataoka, and Y. T. Satoh, *Learning spatio-temporal features with 3d residual networks for action recognition*. Proceedings of the IEEE International Conference on Computer Vision Workshops, arXiv:1708.07632, pp. 3154-3160, 2017.
- [5] Q. A. Al-Hanija, M. A. Smadi, and S. Zein-Sabatto, *Multi-class weather classification using ResNet-18 CNN for autonomous IoT and applications*, 2020 International Conference on Computational Science and Computational Intelligence (CSCI), pp. 1586-1591, 2020.
- [6] H. Song, I. Q. Choi, M. S. Ko, and D. S. Lee, *Life protection system development using CCTV video analysis on Deep learning*, KSDI proceeding Vol. 11, pp. 327-328, Nov. 2017.
- [7] H. J. Lim, S. H. Kim, D. S. Lee, and J. K. Kim, *Smart sensor based social disaster notification system*, KSDI proceeding Vol. 11, pp. 133-136, Nov. 2017.
- [8] I. Haritaoglu, D. Harwood, and L. S. Davis, *Real-time surveillance of people and their activities*, IEEE Transaction on PAMI, Vol. 22, pp. 809-830, Aug. 2000.
- [9] X. C. Zheng, M. Q. Wang, and J. O. Mere, *Comparison of data preprocessing approaches for applying deep learning to human activity recognition in the context of industry 4.0*, Sensors Vol. 18, No. 7, pp. 214-220, 2018.
- [10] G. T. Ahn, Y. S. Hong, Y. J. Song, and W. R. Lee *Intelligent video surveillance system using RFID technology*, Journal of

- IIBC, Vol. 11, No. 1, pp. 133-139, 2011.
- [11] J. H. Bak, J. Y. Min, K. S. Nam, and S. H. Yun, *An in-tunnel traffic accident detection algorithm using CCTV image processing*, Journal of KIISE(Software and Data Eng.) Vol. 4, No. 2, pp. 83-90, 2015.
- [12] D. G. Shen, G. R. Wu, H. I. Suk, *Deep learning in medical image analysis*, Annual Review of Biomedical Eng., Vol. 19, No. 1, pp.221-248, 2017.
- [13] D. W. Lee, *A foot traffic analysis system using CCTV based on artificial intelligence*, KIISE Proceeding, pp. 1498-1500, Jul. 2020.
- [14] K. M. Jung, *A study of data preprocessing for network intrusion detection based on deep learning*, KSCI proceeding Vol. 27 No. 2, pp. 164-166, 2018.
- [15] J. H. Park, *Evaluation of demand power prediction performance based on deep learning algorithm and data preprocessing*, Proceeding of Kiise, pp. 1882-1884, Jul. 2017.

딥 러닝 기반의 CCTV를 활용한 이상 행동 감지 시스템 설계

이용주

한국폴리텍대학 청주캠퍼스 부교수

요 약

영상 데이터를 가장 많이 생산하고, 영상 분석 기술을 가장 적극적으로 활용하고 있는 분야는 단연 CCTV일 것이다. 그동안 주로 방법이나 관제 목적으로 수백 대에서 수천 대에 달하는 CCTV를 운영해왔다. 특히 최근 몇 년 간 스마트시티 프로젝트 등이 추진되면서 공공기관이 운영하는 CCTV 대수는 더욱 늘어나고 있다. 이처럼 방법 및 관제 목적의 CCTV로부

터 수집된 영상 스트림을 지속적으로 분석하기 위해서는 많은 인적 자원이 요구되며, 노동집약적인 감시 카메라 모니터링의 자동화 연구가 불가피하게 되었다.

이러한 문제를 극복하기 위해 본 논문은 딥 러닝 모델인 3D ResNet을 활용하여 CCTV 영상에서 이상 행동을 감지하는 시스템을 구현한다. 이상 행동을 감지하기 위한 방법으로 UCF-Crime 데이터셋을 사용하여 이상 행동과 정상 행동으로 구분하는 2-class 분류 문제를 적용하여 실험한다. 훈련된 모델에 비디오 데이터의 전처리 과정을 거친 데이터를 입력으로 행동패턴을 추론한다. 실험을 통해 관제사들의 인위적 판단이 아닌 딥러닝 시스템 기반의 신뢰도 높은 판단으로 이상행동 패턴을 구분하여 이에 대처할 수 있는 효과를 얻을 수 있다. 향후 추론 모델의 세부행동 패턴의 다양화 및 신뢰도 향상 알고리즘을 통해 구체적인 행동패턴분석을 연구할 수 있으며 그 결과 적은 인력으로도 관제센터의 보다 효율적인 방법시스템 운영을 가능하게 하고 선제적 범죄 예방 효과의 강화를 기대한다.



Yong Ju Lee received the M.S. degree in the Department of Electronic Engineering from Chung Ang University in 1989 and Ph.D. degree in the Department of Electronic Engineering from Chung Nam University in 2001. He has been a professor at Korea Polytechnic University since 1996. He's current research interests include artificial intelligence, IoT, Sensor Network. He is a life member of the KKITS.

E-mail address: yoongju@naver.com